Лабораторные работы по курсу
Информационные технологии 1. Операционные системы

Лабораторная работа 3
Потоки в операционной системе

Москва, 2022

Оглавление

Теоретическая часть

1. Понятие потока в ОС

В предыдущей лабораторной работе было дано определения процесса. Напомним, что процесс - программа во время исполнения или объект, которому выделяются ресурсы вычислительной системы, такие как процессорное время, память и т. д. Каждый процесс, содержит в себе набор последовательно выполняемых инструкций. Такой набор называется **потоком** (*thread*). Не нужно путать его со стандартными потоками ввода-вывода (*streams*). Они отвечают за коммуникацию между процессами.

Каждый процесс как минимум состоит из одного потока. В настоящее время очень популярным решением является применение многопоточности в программировании – создание в рамках одного процесса нескольких потоков, работающих параллельно (квазипараллельно).

Представим следующую ситуацию. Нам необходимо написать программу, которая останавливает свою работу по нажатию кнопки. Если программа будет работать всего в один поток, то придется вместе с логикой программы производить опрос кнопки. Это не является эффективным решением, т. к. в момент нажатия кнопки, возможно выполнение кода программы, а не команды опроса. Таким образом нажатие будет пропущено. Гораздо более эффективным способом является разбиение программы на два потока – один отвечает за логику работы, а второй за работу с кнопкой.

В современном мире растет число процессоров, содержащих в себе несколько ядер. Применяя параллельное программирование, мы можем ускорить работу нашей программы в несколько раз! Однако, обратим внимание на то, что созданные потоки не обязательно будут выполняться параллельно на разных ядрах. На процессоре с одним ядром также возможна многопоточность – потоки будут исполняться квазипараллельно. Другими словами, часть процессорного времени будет выполняться один поток, часть – другой. Эти части настолько малы, что для пользователей создается иллюзия параллельности. Существует высказывание – «*Concurrency is not parallelism*». Если перевод слова *parallelism* не требует пояснений, то *Concurrency* обычно переводят как многопоточность. Т.е. «*многопоточность ≠ параллельность*».

Все потоки создаются в рамках одного процесса. Таким образом, потоки делят одно адресное пространство. Если внутри процесса будет создана глобальная переменная, то она будет видна как из одного потока, так и из другого. Попытка одновременного изменения этой переменной несколькими потоками приведет к неопределенному состоянию. Неизвестно что произошло ранее – запись первым потоком или запись вторым. (Рисунок 1)

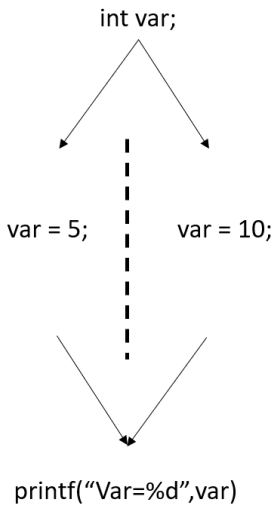

Рисунок 1 Неопределенное состояние

Ситуация, когда две инструкции из разных потоков, одна из которых – инструкция записи, пытаются получить доступ к одной ячейки памяти называется *гонкой данных* или *data race*. Пример, приведенный выше – пример гонки данных. Для безопасной работы с потоками существуют специальные механизмы синхронизации, речь о которых пойдет в следующей лабораторной работе.

2. Организация потоков в ОС Linux

Для создания переносимых многопоточных программ был разработан специальный стандарт *POSIX.1c*. Пакет, предназначенный для работы с потоками, называется pthreads. Таким образом, потоки, созданные с помощью данного пакета, часто называют POSIX потоками. Он поддерживается большинством UNIX систем, однако по умолчанию не поддерживается Windows.

Для создания и управления потоками в C используются следующие основные функции из заголовочного файла «pthreads.h»:

```
int pthread_create(pthread_t *thread, const pthread_attr_t *attr, void *(*start)(void *), void *arg) – функция создания потока;
void pthread_exit(void *retval) – функция для завершения потока;
int pthread_join (pthread_t THREAD_ID, void ** DATA) – функция для ожидания потока;
```

3. Механизмы синхронизации потоков

Для корректной работы многопоточной программы необходимо синхронизировать работу потоков. Для этого существуют несколько стандартных механизмов. Наиболее распространенным и популярным является мьютекс (*mutex).*

*Mutex – (*от англ. *mutual exclusion* — «взаимное исключение») - примитив синхронизации, обеспечивающий взаимное исключение исполнения критических участков кода. Мьютекс можно представить в виде переменной, которую можно перевести в одно из двух состояний – заблокировано и разблокировано. При входе в критическую секцию поток вызывает функцию перевода мьютекса в заблокированное состояние, при этом поток блокируется до освобождения мьютекса, если другой поток

уже владеет им. При выходе из критической секции поток вызывает функцию перевода мьютекса в незаблокированное состояние.

Для работы с мьютексами используются следующие функции:

```
int pthread_mutex_init(pthread_mutex_t *mutex, const pthread_mutexattr_t *attr) - инициализация мьютекса
int pthread_mutex_lock(pthread_mutex_t *mutex) - захват мьютекса
int pthread_mutex_unlock(pthread_mutex_t *mutex) - освобождение мьютекса
```

Помимо обычных мьютексов используются рекурсивные мьютексы. Данный тип отличается от обычных мьютексов тем, что его возможно захватить несоклько раз одним и тем же потоком. Инициализация в POSIX происходит следующим образом:

```
pthread_mutex_t Mutex;
pthread_mutexattr_t Attr;

pthread_mutexattr_init(&Attr);
pthread_mutexattr_settype(&Attr, PTHREAD_MUTEX_RECURSIVE);
pthread_mutex_init(&Mutex, &Attr);
```

4. Интерфейс OpenMP

OpenMP — это библиотека для параллельного программирования вычислительных систем с общей памятью. С ее помощью возможно без особых затрат распараллелить код программы на несколько потоков.

Для использования библиотеки OpenMP вам необходимо подключить заголовочный файл "omp.h", в а также добавить опцию сборки -fopenmp (для компилятора gcc).

После запуска программы создается единственный процесс с единственным потоком, который начинается выполняться, как и обычная последовательная программа. Встретив параллельную область (задаваемую директивой #pragma omp parallel) процесс порождает ряд потоков (их число можно задать явно, однако по умолчанию будет создано столько потоков, сколько в вашей системе вычислительных ядер). Границы параллельной области выделяются фигурными скобками, в конце области потоки уничтожаются. В следующем примере программа выведет на экран сообщение внутри параллельной области несколько раз.

```c
#include <stdio.h>
#include <omp.h>

int main()
{
    printf("Hello!\n");
    #pragma omp parallel
    {
        printf("I'm in the parallel section!\n");
    }
    printf("Goodbye!\n");
        return 0;
}
```

Результат работы программы:

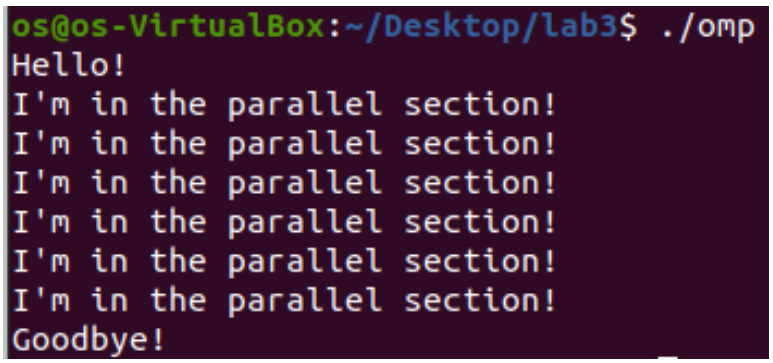

Запуск данной программы производился на 6 ядерном процессоре. Таким образом, мы видим 6 записей в параллельной секции.

Практическая часть

В ходе выполнения практического задания вам необходимо провести эксперименты по расчету численного значения определенного интеграла при различных условиях.

В качестве интеграла предлагается взять следующий: $I = \int_0^1 \frac{4}{1+x^2} dx$

За число разбиений интеграла для вычисления примите значения 10^3, 10^6, 10^9. Результаты экспериментов необходимо заносить в отчет. Полученное время выполнения программ рекомендуется свести в таблицу 1, приведенную ниже.

В **отчет** необходимо добавить графики из задания 3.

Также необходимо указать характеристики устройств, на которых производятся вычисления – название процессора, число ядер, тактовые частоты. Для этого возможно воспользоваться программой CPU-Z.

Для корректной работы на виртуальной машине необходимо включить возможность доступа к нескольким ядрам процессора. Для этого в настройках виртуальной машины (Настройки –> Система -> Процессор) выберете несколько ядер для работы.

4.1. Непосредственное вычисление интеграла.

Изучите приведенный ниже код:

```c
#include <stdio.h>
#include <math.h>
#include <time.h>
#include <stdlib.h>

//Input arguments:
//1: Начало интервала
//2: Конец интервала
//3: Число разбиений
//
//example:
// ./integral 0 10 1000000

double integrate(double a, double b, int n) {

//тут будет ваш код

}

int main(int argc, char* argv[])
{
        double I;
        if (argc != 4) {
                fprintf(stderr, "Not enough arguments\n");
                exit(1);
        }
        long int N = atoi(argv[3]);
        I = integrate(strtod(argv[1], 0), strtod(argv[2], 0), N);
        printf("I = %f\n", I);

        return 0;
}
```

Создайте файл integral.c и скопируйте в него данную программу. Дополните функцию rectangle_integral, чтобы она возвращала значение посчитанного интеграла. Скомпилируйте проект и запустите его на виртуальной машине.

Для компиляции воспользуйтесь следующим ключом:

gcc integral.c -o integral -lm

Сверьте решение, полученное вашей программой с точным решением. (Например, полученным с помощью онлайн калькулятора)

С помощью утилиты time замерьте время выполнения вашей программы

time ./integral 0 10 1000000

Требуемое значение будет выведено в строке real.

4.2. Разбиение вычисления выполнения интеграла на несколько процессов

Изучите приведенный ниже код:

```c
#include <stdio.h>
#include <stdlib.h>
#include <unistd.h>
#include <sys/wait.h>
#include <math.h>

double integrate(double a, double b, double n) {

	//тут будет ваш код

}

int main(int argc, char* argv[])
{
	double I;
	if (argc != 4) {
		fprintf(stderr, "Not enough arguments\n");
		exit(1);
	}
	long int N = atoi(argv[3]);

	int n;
	int fds[2];
	pid_t pid;
	pipe(fds);
	pid = fork();
	if (pid != (pid_t)0)
	{
		double r1 = 0, r2 = 0;
		int s;
		close(fds[1]);
		r1 = integrate(strtod(argv[1], 0), strtod(argv[2], 0) / 2, N / 2);
		read(fds[0], &r2, sizeof(double));
		close(fds[0]);
		printf("I = %g\n", r1 + r2);
		wait(&s);
		return 0;
	}
	else
	{
		double s;
		close(fds[0]);
		s = integrate(strtod(argv[2], 0) / 2, strtod(argv[2], 0), N / 2);
		write(fds[1], &s, sizeof(double));
		close(fds[1]);
		return 0;
	}
}
```

Аналогично заданию 1 дополните код программы. Запустите ее и убедитесь, что значение рассчитано верно.

Замерьте время выполнения программы. Сравните с п.1 Сделайте выводы.

4.3. Вычисление интеграла с помощью POSIX threads

Изучите приведенный ниже код:

```
#include <stdio.h>
#include <pthread.h>
#include <stdlib.h>
#include <math.h>

double integrate(double a, double b, double n) {

//тут будет ваш код

}

struct IntegrateTask { // Шаблон для структуры "Задача потоку"
	double from, to, step, res; // интегрировать "от" (from), "до" (to), с "шагом" (step), результат сохранить в res
};

void* integrateThread(void* data) { // ф-я приведения типов задания и т.д.
	struct IntegrateTask* task = (struct IntegrateTask*)data; // объявления структуры task и присвоения аргументов
	task->res = integrate(task->from, task->to, task->step); // вызов ф-и интегрирования с передачей параметров (задача)

	pthread_exit(NULL); // завершение потока
}


int main(int argc, char* argv[]) {

	double I;
	if (argc != 5) {
		fprintf(stderr, "Not enough arguments\n");
		exit(1);
	}
	long int N = atoi(argv[3]);
	long int NUM_THREADS = atoi(argv[4]);
	pthread_t threads[NUM_THREADS]; // Объявляем массив структур потоков (системные)
	struct IntegrateTask tasks[NUM_THREADS]; // Объявляем массив структур заданий потокам

	struct IntegrateTask mainTask = { strtod(argv[1],0),strtod(argv[2],0),N / NUM_THREADS }; // Общее задание, интегрировать от 0 до 10 с шагом 00000001
	double distance = (mainTask.to - mainTask.from) / NUM_THREADS; // Делим общее задание на части
	int i;

	for (i = 0; i < NUM_THREADS; ++i) // создаем задания и потоки
	{
		tasks[i].from = mainTask.from + i * distance; // задаем "от"
		tasks[i].to = mainTask.from + (i + 1) * distance; // задаем "до"
		tasks[i].step = mainTask.step; // задаем "шаг"

		pthread_create(&threads[i], NULL, integrateThread, (void*)& tasks[i]); // создание потоков и передача параметров (задания)
	}

	double res = 0;
	for (i = 0; i < NUM_THREADS; ++i)
	{ // Барьер
		pthread_join(threads[i], NULL); // ждем завершения потока
		res += tasks[i].res; // суммируем результаты
	}
	printf("I = %lf \n", res);

	return 0;
}
```

Аналогично заданию 1 дополните код программы.

Скомпилируйте ее с помощью следующей команды:

gcc integral.c -o integral -lm -lpthread

Запустите ее и убедитесь, что значение рассчитано верно.

*Рассчитайте время выполнения программы при различном числе потоков – от 1 до 8. Постройте **график** зависимости время выполнения от числа потоков.*

Сравните время выполнения программы, выполняемой двумя потоками с программой из задания 2. Объясните полученный результат.

4.4. Использование директив OpenMP

Исправьте код программы из задания 1, добавив в функцию `integrate` перед циклом for следующую строчку:

```
#pragma omp parallel for reduction(+:sum)
```

Где sum – накапливаемая сумма при расчете интеграла.

Скомпилируйте программу с помощью следующей команды:

gcc integral.c -o integral -lm -fopenmp

Запустите программу и вычислите время выполнения. Сравните его со временем выполнения программы предыдущих заданий.

Таблица 1. Сравнение времени выполнения программ

Задание	Время выполнения (*сек*)		
	$n=10^3$	$n=10^6$	$n=10^9$
Последовательное выполнение (задания 1)			
Выполнение двумя процессами (задание 2)			
Выполнение с помощью POSIX threads (задание 3)			
Число потоков			
1			
2			
3			
4			
5			
6			
7			
8			
Выполнение с помощью OMP (задание 4)			

Контрольные вопросы

1. Какие основные отличия между процессами и потоками?
2. В чем преимущества использования потоков?
3. Для чего используется интерфейс OpenMP?

Список рекомендованной литературы

1. Э. Таненбаум и Х. Бос, Современные операционные системы, Санкт-Петербург: Питер, 2021, с. 1119.
2. В. Е. Карпов и К. А. Коньков, Основы операционных систем, Москва: Физматкнига, 2019, с. 326.
3. Учебник по OpenMP [Электронный ресурс] // Блог программиста: [сайт]. [2018]. URL: https://pro-prof.com/archives/4335 (дата обращения: 12.09.2022).